DATA SCIENTIST CHALLENGE 2026

INTERBANK: Transformación de la Evaluación Crediticia

Implementación de Machine Learning para la Optimización del Riesgo

EL PARADIGMA DEL RIESGO

⚠️ Situación Actual

La cartera de préstamos presenta un evidente **aumento en el deterioro**. Esto genera una alta exposición a pérdidas financieras y evidencia una baja eficiencia en el proceso tradicional de aprobación crediticia.

💡 Propuesta de Valor

Convertir datos históricos en **inteligencia predictiva**. Desarrollar un sistema de pre-evaluación automatizado (ML) para anticipar el riesgo de default (mora >90 días) en los próximos 24 meses.

IMPACTO ESTRATÉGICO ESPERADO

Eficiencia Operativa

Apoyar decisiones estratégicas agilizando y optimizando el proceso de aprobación de préstamos.

Control de Riesgo

Implementar un monitoreo predictivo que garantice un mejor control del riesgo crediticio global.

Reducción de Pérdidas

Disminución sistemática de las pérdidas monetarias por mora y deterioro general de la cartera.

DATOS & PREPROCESAMIENTO

Dataset: 150.000 registros, 3 años de historia. Target desbalanceado (~6.7% Default).

Variables: Historial, Capacidad, Uso y Demografía.

Pipeline de Ingeniería:

- **Auditoría:** Corrección de inconsistencias.
- **Protección:** Límites y winsorización de outliers.
- **Estabilización:** Transformación Log (Ingresos).
- **Preservación:** Variables de mora intactas.

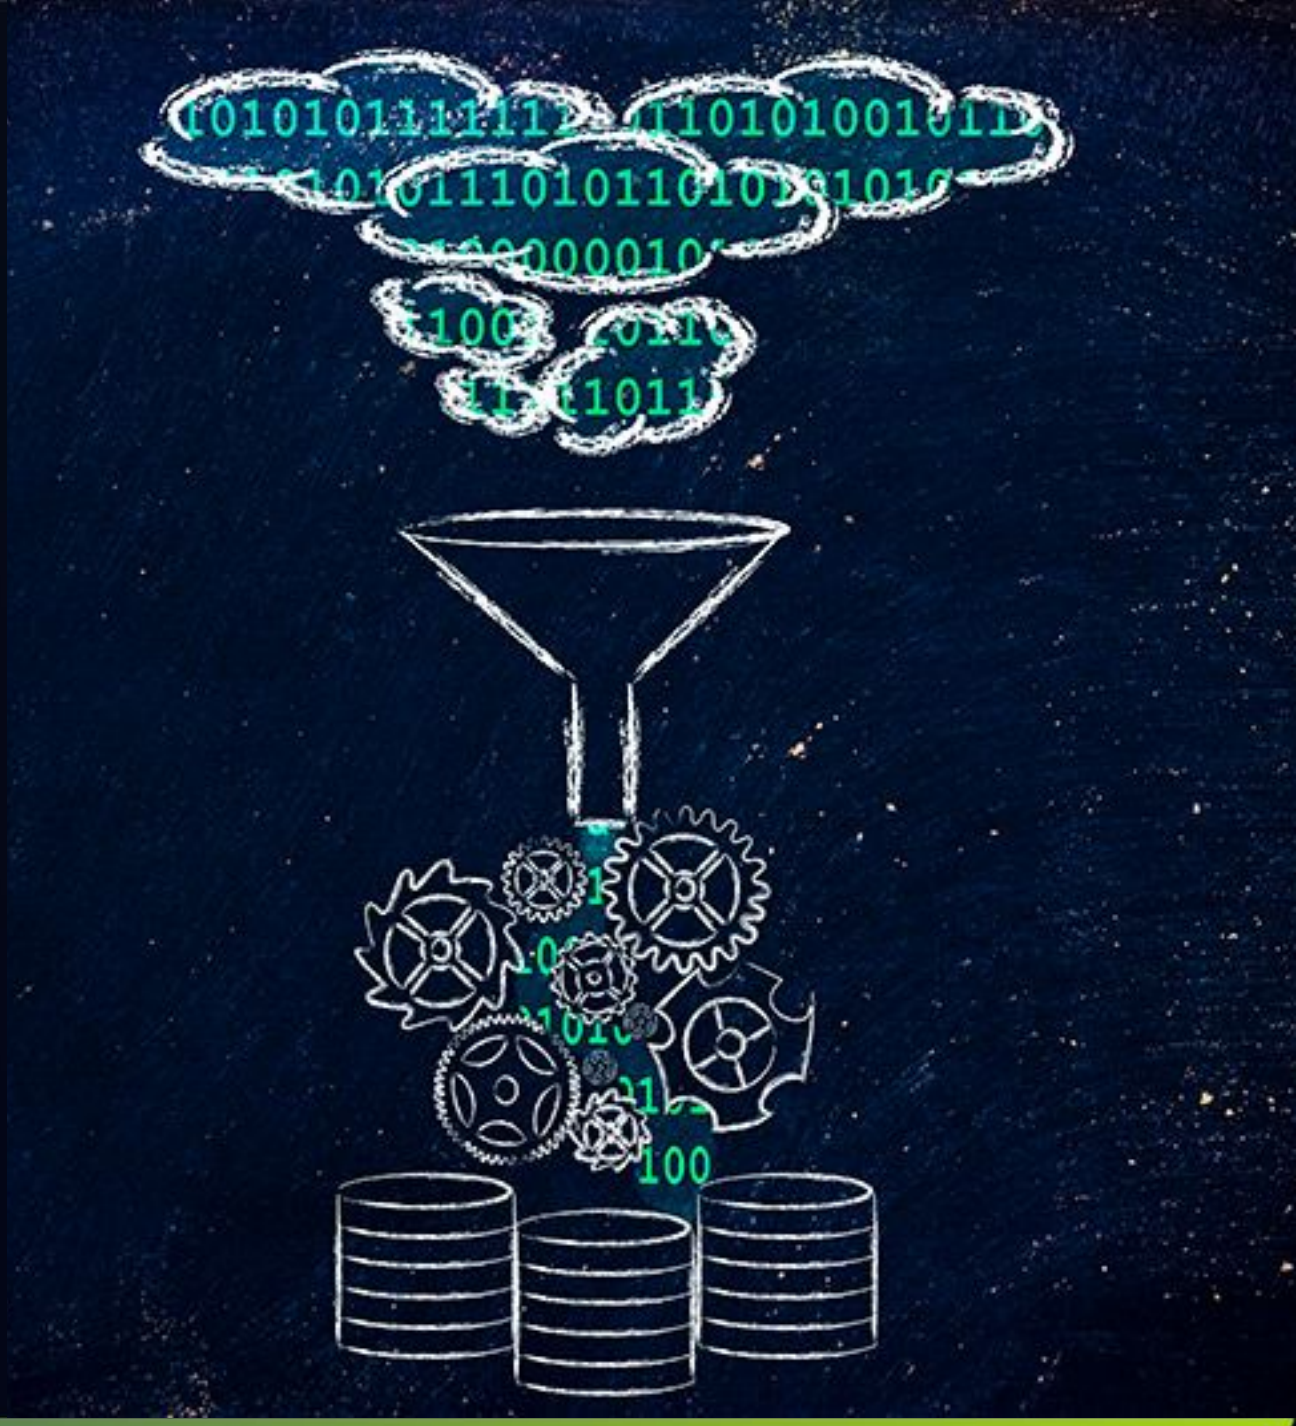

ANÁLISIS DESCRIPTIVO: HALLAZGOS

- **1. El historial de pago es el principal factor que explica el riesgo**: A mayor cantidad de retrasos (mayores a 30 o 60 días), mayor es la probabilidad de incumplimiento futuro.
- **2. Estrés financiero:** El 10% de clientes con mayor uso de tarjeta concentra defaults > 20%.
- **3. Sobreendeudamiento:** Deciles superiores del ratio deuda/ingreso duplican el incumplimiento.
- **4. Ingreso protector:** Relación inversa clara (Mayores ingresos → menor riesgo).

EVALUACIÓN DE MODELOS PREDICTIVOS

Modelo Evaluado	AUC (ROC)	GINI	Cutoff	Approval Rate
Regresión Logística (Baseline)	0.83	0.66	0.30	~61%
Random Forest	0.86	0.72	0.30	~59%
LightGBM (Modelo Seleccionado)	**0.87**	**0.73**	**0.30**	**58.26%**

LightGBM es seleccionado para optimización por su mayor capacidad para separar clientes en riesgo, mejorando significativamente la detección (Recall 81%) manteniendo la rentabilidad.

FEATURES DE DECISIÓN (IMPORTANCE)

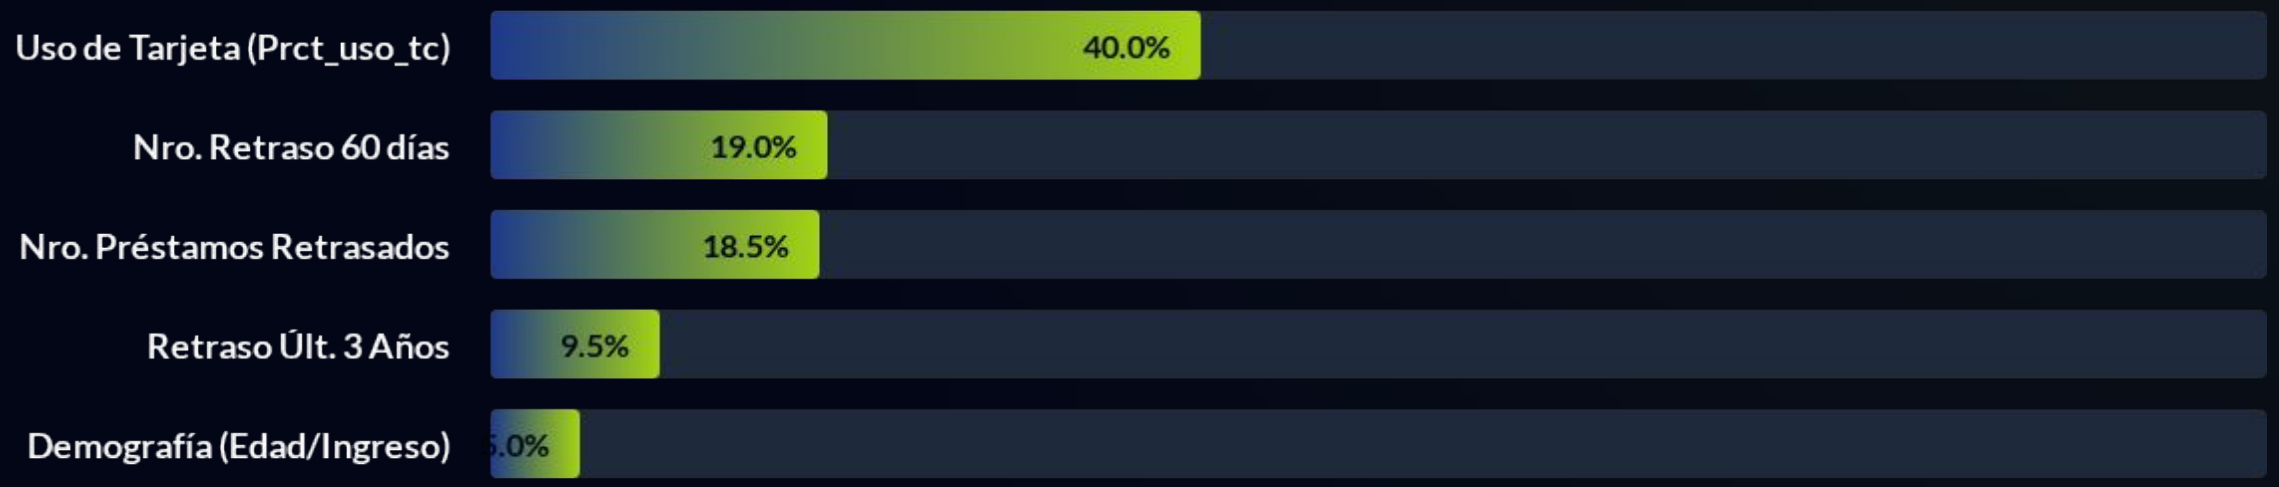

*Conclusión: El modelo se basa en **comportamiento financiero real** (uso de línea y mora pasada), no en características personales o estructurales.*

RIESGO VS. PROBABILIDAD ESTIMADA

Rango de Probabilidad	Q Total	Q Impago	Ratio de Mora
(-0.001, 0.1]	28,641	91	0.32%
(0.1, 0.2]	38,793	409	1.05%
(0.2, 0.3]	19,962	448	2.24%
(0.3, 0.4]	14,354	513	3.57%
(0.4, 0.5]	12,065	670	5.55%
(0.5, 0.6]	10,712	915	8.54%
(0.6, 0.7]	8,294	1,008	12.15%
(0.7, 0.8]	5,742	1,175	20.46%
(0.8, 0.9]	6,311	2,012	31.88%
(0.9, 1.0]	5,125	2,785	54.34%

Hasta 30% de Probabilidad (PD), la mora se mantiene en niveles mínimos. **A partir del 40%, el riesgo se dispara y deteriora la cartera.**

¿Cómo lo aplicamos al Negocio?

El Problema Actual

Las políticas estáticas y la falta de diferenciación predictiva generan aprobación de clientes en alto riesgo oculto. **El volumen crece, pero la calidad se deteriora.**

La Solución AI

Al implementar el modelo, establecemos un corte matemático. **Excluimos de manera precisa al segmento de mayor riesgo,** protegiendo el capital del banco sin frenar el negocio.

SIMULACIÓN DEL BUSINESS CASE

ESCENARIO ACTUAL (Sin Modelo)

Solicitudes / mes: 10,000

Aprobación: 100% (10,000 clientes)

Ratio Mora: 6.68% (668 clientes morosos)

💸 Pérdida Mensual: S/ 668,000

💸 Pérdida Anual: S/ 8.0 MM

CON MODELO (Aprobar PD < 0.30)

Solicitudes / mes: 10,000

Aprobación: 58.26% (5,826 clientes)

Ratio Mora: 1.08% (63 clientes morosos)

💸 Pérdida Mensual: S/ 63,000

💸 Pérdida Anual: S/ 0.76 MM

IMPACTO FINANCIERO DIRECTO

Al implementar el umbral predictivo de Machine Learning, el negocio recupera liquidez inmediata:

S/ 605K
AHORRO MENSUAL

S/ 7.26M
AHORRO ANUAL (SOLES)

** Estos ahorros representan capital que el banco puede reinvertir para apalancar segmentos de bajo riesgo y mayor rentabilidad.*

"

El modelo permite reducir más del **90% de la pérdida esperada**, manteniendo un 58% de aprobación bajo un criterio objetivo de riesgo.

— Interbank Data Scientist Challenge

¿Preguntas?

Rediseñando la Estrategia Crediticia

DATA CHALLENGE 2026